

데이터 품질과 전처리 이해

AI 기획자는 데이터를 직접 고치는 사람이 아니라, 데이터가 AI 서비스에 쓰일 만큼 믿을 수 있는 상태인지 판단할 수 있는 사람이어야 합니다.

학습 목표

- 데이터 품질이 AI 서비스에 왜 중요한지 설명할 수 있다.
- 결측치와 이상치가 무엇인지 이해할 수 있다.
- 전처리가 왜 필요한지 기획자 관점에서 설명할 수 있다.
- 데이터 품질 문제가 AI 성능과 사용자 경험에 미치는 영향을 말할 수 있다.

오늘의 핵심 질문

오늘은 어려운 통계나 코딩을 배우는 시간이 아닙니다.

AI 기획자가 다음 질문을 할 수 있도록 만드는 시간입니다.

- 이 데이터에 빠진 값은 없는가?
- 너무 이상한 값은 없는가?
- 같은 의미가 여러 방식으로 적혀 있지 않은가?
- AI가 이 데이터를 그대로 사용해도 되는가?
- 데이터 문제가 사용자에게 어떤 피해를 줄 수 있는가?

데이터 품질이란?

데이터 품질은 데이터가 **서비스 목적에 맞게 믿고 사용할 수 있는 정도**입니다.

좋은 데이터는 다음 조건을 만족합니다.

- 필요한 항목이 들어 있다.
- 값이 비어 있지 않다.
- 값이 너무 이상하지 않다.
- 같은 기준으로 입력되어 있다.
- 최신 상태에 가깝다.
- 출처와 의미를 설명할 수 있다.

AI 서비스에서 데이터 품질이 중요한 이유

AI는 데이터를 근거로 답하고 추천합니다.

데이터 품질이 낮으면 AI 기능도 불안정해집니다.

데이터 문제	AI 서비스 결과
값이 빠져 있음	조건을 제대로 반영하지 못함
값이 틀림	잘못된 답변이나 추천
값이 오래됨	현재와 맞지 않는 안내
표현이 제각각임	같은 대상을 다르게 인식
극단값이 섞임	평균, 추천, 예측이 왜곡

AI는 나쁜 데이터를 자동으로 고치지 않는다

AI가 똑똑해 보여도 데이터 문제를 항상 알아서 해결하지는 못합니다.

예를 들어,

- 나이가 비어 있는 사용자를 어떻게 처리할지
- 가격이 0원인 상품을 정상으로 볼지
- 리뷰 점수가 5점 만점인데 99점이 들어온 경우
- 같은 지역이 "서울", "서울시", "Seoul"로 섞인 경우

이런 문제는 AI 기능 이전에 정리 기준이 필요합니다.

전처리란?

전처리는 데이터를 AI나 서비스가 사용할 수 있도록 미리 정리하는 과정입니다.

쉽게 말하면,

원본 데이터



틀린 값, 빈 값, 이상한 값 확인



기준에 맞게 정리



AI 서비스에 사용할 수 있는 데이터

전처리를 왜 해야 하는가?

전처리는 데이터를 예쁘게 만드는 작업이 아닙니다.

AI가 잘못 판단하지 않도록 **데이터를 서비스 기준에 맞추는 작업**입니다.

- 빠진 값을 확인한다.
- 이상한 값을 찾는다.
- 단위와 표현을 맞춘다.
- 중복을 정리한다.
- 필요 없는 항목을 제거한다.
- 개인정보나 민감정보를 조심한다.

기획자가 전처리를 알아야 하는 이유

AI 기획자가 직접 전처리를 수행하지 않아도, 전처리의 필요성은 이해해야 합니다.

기획 상황	필요한 판단
기능 범위 정하기	지금 데이터로 가능한 기능인지 판단
일정 산정	데이터 정리에 시간이 필요한지 판단
요구사항 작성	어떤 품질 기준이 필요한지 작성
테스트 설계	어떤 데이터 문제가 발생할 수 있는지 확인
사용자 안내	결과가 제한될 수 있는 상황 설명

결측치란?

결측치는 데이터에서 값이 비어 있는 상태를 말합니다.

예를 들어,

이름	나이	지역	관심사
김민수	28	서울	운동
이서연		부산	여행
박지훈	35		음악

나이와 지역처럼 비어 있는 값이 결측치입니다.

결측치는 왜 생길까?

결측치는 여러 이유로 생깁니다.

- 사용자가 입력하지 않았다.
- 수집 과정에서 누락되었다.
- 원래 해당 없는 값이다.
- 시스템 오류로 저장되지 않았다.
- 개인정보라 일부러 수집하지 않았다.
- 아직 확인되지 않은 정보다.

비어 있다고 해서 모두 같은 의미는 아닙니다.

결측치에서 가장 중요한 질문

기획자는 먼저 결측치의 의미를 물어야 합니다.

질문	이유
왜 비어 있는가?	실수인지, 의도인지 구분
꼭 필요한 값인가?	기능 동작에 필수인지 판단
다른 값으로 대신할 수 있는가?	대체 가능성 확인
사용자에게 다시 물어봐야 하는가?	입력 흐름 개선
비워 둔 채 사용해도 되는가?	서비스 위험 판단

결측치를 무시하면 생기는 문제

결측치를 그냥 두면 AI 결과가 흔들릴 수 있습니다.

- 개인화 추천이 부정확해진다.
- 특정 사용자가 분석에서 제외된다.
- 평균이나 비율이 왜곡된다.
- AI가 부족한 정보를 추측할 수 있다.
- 사용자에게 엉뚱한 질문이나 답변을 할 수 있다.

결측치 처리 방향

결측치를 처리하는 방법은 하나가 아닙니다.

방법	의미	기획자가 확인할 점
다시 입력 받기	사용자에게 값을 요청	사용자 부담이 커지지 않는가
제외하기	해당 데이터를 사용하지 않음	중요한 사용자가 빠지지 않는가
대체하기	평균값, 기본값 등으로 채움	왜곡이 생기지 않는가
모름으로 표시	알 수 없음 상태로 유지	AI가 추측하지 않게 할 수 있는가

이상치란?

이상치는 일반적인 범위에서 크게 벗어난 값입니다.

예를 들어,

항목	일반적인 값	이상해 보이는 값
나이	20, 35, 48	999
가격	10,000원	-5,000원
평점	1~5점	99점
구매수량	1~10개	10,000개

이상치는 무조건 틀린 값일까?

이상치가 항상 오류는 아닙니다.

진짜 특별한 사례일 수도 있습니다.

가능성	예시
입력 오류	나이에 999 입력
단위 오류	10kg을 10g처럼 입력
시스템 오류	가격이 음수로 저장
진짜 특이 사례	매우 큰 주문량
이벤트 효과	할인 행사로 갑자기 구매 증가

이상치는 지우기 전에 이유를 확인해야 합니다.

이상치를 무시하면 생기는 문제

이상치가 섞이면 AI 판단이 왜곡될 수 있습니다.

- 평균값이 크게 흔들린다.
- 추천 기준이 이상해진다.
- 인기 상품이나 주요 사용자를 잘못 판단한다.
- 예측 결과가 과장될 수 있다.
- 운영자가 문제를 늦게 발견할 수 있다.

이상치에서 기획자가 물어볼 질문

질문	의미
정상 범위는 어디까지인가?	서비스 기준 확인
이 값은 실제 가능한가?	현실성 확인
입력 오류일 가능성이 있는가?	데이터 수집 방식 확인
그대로 두면 AI 결과에 영향이 큰가?	위험도 판단
사용자에게 보여도 되는 값인가?	UX와 신뢰도 확인

전처리는 기준을 정하는 일이다

전처리는 단순히 데이터를 삭제하거나 수정하는 일이 아닙니다.

기획 관점에서는 **어떤 값을 정상으로 볼 것인가**를 정하는 일입니다.

예를 들어,

- 나이는 0세 이상 120세 이하만 허용한다.
- 평점은 1점부터 5점까지만 허용한다.
- 가격은 0보다 커야 한다.
- 지역명은 정해진 목록에서 선택하게 한다.
- 필수값이 비어 있으면 다음 단계로 진행하지 않는다.

데이터 품질 기준 예시

AI 기능을 만들기 전, 간단한 품질 기준을 정해 둘 수 있습니다.

항목	품질 기준 예시
필수값	사용자 ID, 상품명은 비어 있으면 안 됨
범위	나이는 0~120 사이
형식	날짜는 YYYY-MM-DD 형식
중복	같은 상품 ID는 한 번만 존재
단위	가격은 원화 기준
최신성	최근 1년 데이터 사용

데이터 품질이 AI 성능에 미치는 영향

데이터 품질은 AI의 정확도뿐 아니라 사용자 경험에도 영향을 줍니다.

품질 문제	AI 성능 영향	사용자 경험 영향
결측치	조건 반영 실패	맞지 않는 추천
이상치	판단 기준 왜곡	이상한 결과 노출
중복	특정 결과 과대표현	같은 답변 반복
오래된 데이터	최신 상황 반영 실패	신뢰도 하락
표현 불일치	같은 대상을 다르게 인식	검색 결과 누락

추천 AI에서 생기는 문제

추천 AI는 데이터 품질 영향을 크게 받습니다.

예를 들어,

- 사용자 선호 정보가 비어 있으면 추천이 일반적이 된다.
- 상품 카테고리가 틀리면 엉뚱한 상품이 추천된다.
- 평점 데이터에 이상치가 있으면 인기 상품 판단이 왜곡된다.
- 오래된 구매 이력만 있으면 현재 관심사를 반영하지 못한다.

챗봇 AI에서 생기는 문제

챗봇은 답변 근거 데이터의 품질이 중요합니다.

- FAQ가 오래되면 틀린 정책을 안내한다.
- 문서에 빈 내용이 많으면 답변이 부실해진다.
- 같은 질문에 대한 답이 여러 문서에서 다르면 답변이 흔들린다.
- 출처가 불분명하면 사용자가 답변을 믿기 어렵다.

검색 AI에서 생기는 문제

검색 기능도 데이터 품질의 영향을 받습니다.

- 제목이나 키워드가 비어 있으면 검색되지 않는다.
- 같은 단어가 여러 표현으로 섞이면 결과가 빠진다.
- 잘못된 태그가 있으면 엉뚱한 결과가 나온다.
- 오래된 문서가 먼저 나오면 사용자가 혼란스러워진다.

데이터 품질은 성능만의 문제가 아니다

데이터 품질 문제는 단순히 "AI가 조금 틀리는 문제"가 아닙니다.

서비스 전체의 신뢰와 연결됩니다.

- 사용자가 AI 답변을 믿지 않게 된다.
- CS 문의가 늘어난다.
- 잘못된 정보로 피해가 생길 수 있다.
- 운영자가 결과를 설명하기 어려워진다.
- 서비스 개선 방향을 잘못 판단할 수 있다.

AI가 추측하지 않게 하기

데이터가 부족할 때 AI가 추측하지 않도록 규칙을 정해야 합니다.

- 필요한 데이터가 없으면 "확인할 수 없습니다"라고 답한다.
- 오래된 정보는 최신 확인이 필요하다고 안내한다.
- 근거가 없는 추천은 하지 않는다.
- 사용자가 직접 입력해야 하는 정보는 다시 요청한다.
- 민감한 판단은 담당자 확인이 필요하다고 안내한다.

기획자가 회의에서 던질 질문

데이터 품질을 논의할 때 다음 질문을 던질 수 있으면 충분합니다.

- 이 데이터에서 꼭 필요한 값은 무엇인가?
- 비어 있으면 안 되는 항목은 무엇인가?
- 정상 범위는 어디까지인가?
- 이상한 값이 들어오면 어떻게 처리할 것인가?
- 오래된 데이터는 어떻게 구분할 것인가?
- AI가 근거 없는 답을 하지 않게 하려면 어떤 규칙이 필요한가?

너무 어렵게 생각하지 않기

AI 기획자가 전처리 코드를 직접 작성할 필요는 없습니다.

하지만 다음 감각은 꼭 필요합니다.

- 빈값은 AI 판단을 약하게 만든다.
- 이상한 값은 AI 판단을 왜곡한다.
- 같은 표현은 같은 방식으로 정리되어야 한다.
- 데이터 품질 기준은 기능 요구사항과 함께 정해야 한다.
- 데이터 문제가 사용자 경험 문제로 이어질 수 있다.

핵심 정리

- 데이터 품질은 AI 서비스의 신뢰도와 직결된다.
- 결측치는 값이 비어 있는 상태이며, 이유를 먼저 확인해야 한다.
- 이상치는 일반적인 범위에서 벗어난 값이며, 오류인지 특이 사례인지 구분해야 한다.
- 전처리는 AI가 데이터를 안정적으로 쓰도록 정리하는 과정이다.
- 데이터 품질이 낮으면 AI 성능뿐 아니라 사용자 경험도 나빠진다.
- AI 기획자는 데이터 품질 문제를 발견하고 질문할 수 있어야 한다.

오늘 기억할 문장

| 좋은 AI는 좋은 모델만으로 만들어지지 않습니다.

| AI가 믿고 사용할 수 있는 데이터가 있어야 좋은 서비스가 됩니다.