

RAG 데이터 설계

AI가 참고할 문서를 어떻게 고르고 정리할 것인가

오늘의 전제

이전 수업에서 RAG 서비스 구조를 배웠습니다.

오늘은 Retriever, Vector DB, LLM의 구조를 다시 설명하기보다
그 구조 안에 들어갈 **데이터를 어떻게 설계할지**에 집중합니다.

기획자가 정해야 할 질문은 이것입니다.

AI가 답변할 때 믿고 참고해도 되는 자료는 무엇인가?

오늘의 핵심 질문

RAG 데이터 설계는 문서를 많이 넣는 일이 아닙니다.

기획자는 다음을 판단해야 합니다.

- 어떤 문서를 넣을 것인가?
- 어떤 문서는 제외할 것인가?
- 문서를 어떤 단위로 나눌 것인가?
- 문서 조각에 어떤 설명 정보를 붙일 것인가?
- 오래된 문서와 충돌하는 문서는 어떻게 관리할 것인가?

RAG의 답변 품질은 데이터 준비 방식에서 크게 달라집니다.

RAG 데이터 설계란?

RAG 데이터 설계는 AI가 참고할 지식을
검색하기 좋은 형태로 정리하는 일입니다.

쉽게 말하면,

서비스 안의 문서를 AI가 찾아보고 답할 수 있도록
기준을 세우고 구조화하는 과정입니다.

문서가 부정확하거나 정리되어 있지 않으면
AI도 부정확한 근거를 보고 답하게 됩니다.

서비스 질문에서 출발하기

데이터 설계는 문서 목록보다 사용자 질문에서 시작합니다.

예를 들어 건강기능식품 쇼핑몰이라면
사용자는 이런 질문을 할 수 있습니다.

- 이 제품을 임산부가 먹어도 되나요?
- 알레르기 유발 성분이 있나요?
- 하루에 몇 번 먹어야 하나요?
- 다른 제품과 무엇이 다른가요?
- 환불이나 교환이 가능한가요?

질문을 먼저 정리해야 필요한 문서가 보입니다.

질문과 근거 문서 연결하기

사용자 질문마다 필요한 근거 문서는 다를 수 있습니다.

사용자 질문	필요한 근거 문서
복용 가능 여부	성분표, 주의사항, FAQ
섭취 방법	상품 설명, 섭취 가이드
부작용 우려	주의사항, 전문가 안내 문구
배송/환불	배송 정책, 교환/환불 정책
제품 비교	상품별 성분, 가격, 대상 고객

RAG 데이터 설계의 첫 단계는
질문과 근거 문서를 짝지어 보는 것입니다.

넣을 문서와 제외할 문서

RAG에 넣을 문서는 답변 근거가 될 수 있어야 합니다.

구분	판단 기준
넣을 문서	사용자 질문에 직접 답할 수 있음
보류할 문서	내용은 유용하지만 최신성이나 출처 확인이 필요함
제외할 문서	오래되었거나 중복, 충돌, 비공개 정보가 포함됨

문서를 많이 넣으면 좋아지는 것이 아니라
믿을 수 있는 문서를 넣어야 좋아집니다.

좋은 RAG 문서의 조건

RAG에 적합한 문서는 다음 조건을 갖습니다.

- 질문에 대한 답이나 판단 근거가 들어 있음
- 작성 기준과 출처가 명확함
- 최신 상태로 관리될 수 있음
- 중복되거나 서로 충돌하는 내용이 적음
- 제목, 항목, 조건, 예외가 구분되어 있음
- 사용자에게 공개해도 되는 내용만 포함함

AI에게 보여줄 문서는 내부 보관용 문서와 기준이 다를 수 있습니다.

문서 목록표 만들기

기획자는 먼저 사용할 문서를 목록화합니다.

문서명	문서 유형	답할 수 있는 질문	관리 부서	공개 가능 여부
상품 상세 설명	상품 정보	성분, 섭취 방법	상품팀	가능
섭취 주의사항	안전 안내	임산부, 알레르기	품질팀	가능
상담 매뉴얼	고객지원	예외 상황 대응	CS팀	일부 가능
내부 승인 기준	운영 기준	판매 가능 여부	운영팀	불가

문서 목록표는 개발 전에 만드는 데이터 설계의 출발점입니다.

문서 관리 기준

RAG에서는 오래된 문서도 답변 근거가 될 수 있습니다.

그래서 문서마다 관리 기준이 필요합니다.

관리 항목	확인 질문
소유자	이 문서는 누가 관리하는가?
업데이트 주기	언제 최신화되는가?
버전	이전 내용과 최신 내용을 구분할 수 있는가?
공개 범위	사용자가 봐도 되는 정보인가?
삭제 기준	더 이상 쓰지 않는 문서는 어떻게 제외하는가?
충돌 기준	문서끼리 다르다면 무엇을 우선할 것인가?

청킹을 바라보는 관점

청킹은 문서를 작게 자르는 기술 작업처럼 보일 수 있습니다.

하지만 기획 관점에서는

사용자 질문에 답하기 좋은 단위로 문서를 나누는 일입니다.

예를 들어 하나의 상품 상세 페이지도

다음 정보는 따로 다루는 편이 좋습니다.

- 상품 기본 정보
- 주요 성분
- 섭취 방법
- 섭취 주의사항
- 자주 묻는 질문

Chunk를 나누는 기준

좋은 Chunk는 하나의 질문에 답할 만큼 충분해야 합니다.

나누는 기준	적합한 문서
제목 기준	매뉴얼, 정책 문서
질문 기준	FAQ, 상담 스크립트
항목 기준	상품 정보, 성분표, 비교표
조건 기준	환불 조건, 예외 정책, 주의사항

기준은 문서 모양이 아니라
사용자가 어떤 질문을 할지에 맞춰 정합니다.

좋지 않은 Chunk 예시

Chunk를 잘못 나누면 검색 결과가 흔들립니다.

문제	사용자 경험
너무 크게 나눔	관련 없는 정보까지 답변에 섞임
너무 작게 나눔	필요한 조건이나 예외가 빠짐
제목 없이 나눔	어떤 문서의 내용인지 알기 어려움
표를 중간에 자름	기준, 수치, 조건이 끊어짐
서로 다른 주제를 섞음	답변이 모호하거나 틀릴 수 있음

Chunk 하나만 봐도 무슨 내용인지 알 수 있어야 합니다.

Chunk 설계 예시

원문:

비타민D 1000IU는 하루 1회 섭취합니다. 임산부, 수유부, 특정 질환이 있는 경우 전문가와 상담 후 섭취하세요.

좋은 Chunk:

항목	내용
제목	비타민D 1000IU 섭취 방법 및 주의사항
본문	하루 1회 섭취. 임산부, 수유부, 특정 질환자는 전문가 상담 필요
답할 질문	복용량, 임산부 섭취 가능 여부, 주의 대상

단순히 길이로 자르기보다 답변 단위로 정리합니다.

메타데이터란?

메타데이터는 문서 조각에 붙이는 설명 정보입니다.

AI가 문서를 찾을 때 검색 범위를 좁히고, 사용자에게 출처를 보여주기 위해 필요합니다.

메타데이터	예시
문서 유형	상품 설명, FAQ, 정책
상품명	비타민D 1000IU
카테고리	영양제, 뼈 건강
작성일	2026-07-01
관리 부서	상품팀
공개 범위	전체 사용자 공개

메타데이터를 설계할 때 볼 것

메타데이터는 많이 붙이는 것보다 검색과 운영에 실제로 쓰이는 것이 중요합니다.

기획자는 다음을 확인합니다.

- 사용자가 상품명이나 카테고리로 질문하는가?
- 최신 문서를 우선해야 하는가?
- 사용자 권한에 따라 보여줄 문서가 달라지는가?
- 답변에 출처 제목이나 URL을 보여줘야 하는가?
- 특정 부서가 관리하는 문서를 구분해야 하는가?

메타데이터는 검색 품질과 서비스 운영을 함께 돕습니다.

출처 정보 설계

RAG 답변은 근거를 보여줄 수 있어야 신뢰를 얻습니다.

항목	예시
문서 제목	비타민D 1000IU 상품 상세
문서 위치	상품 상세 페이지 URL
작성일/수정일	2026-07-01
담당 부서	상품팀
사용자 표시명	제품 상세 설명

내부 파일명 그대로 보여주기보다 사용자가 이해할 수 있는 출처명으로 설계해야 합니다.

권한과 민감 정보

RAG 데이터에는 사용자에게 보여주면 안 되는 정보가 섞일 수 있습니다.

예를 들어 다음 정보는 주의가 필요합니다.

- 내부 원가, 마진, 협상 내용
- 직원 개인정보 또는 고객 개인정보
- 공개 전 상품 정보
- 내부 승인 기준이나 비공개 운영 정책
- 법무, 의료, 금융 판단처럼 오해 위험이 큰 내용

RAG 데이터 설계에서는

검색되면 안 되는 정보도 함께 정의해야 합니다.

충돌하는 문서 처리

문서마다 내용이 다르면 AI 답변도 흔들립니다.

예를 들어 한 문서에는 "7일 이내 환불 가능",
다른 문서에는 "14일 이내 환불 가능"이라고 적혀 있다면
AI는 어떤 기준으로 답해야 할지 알기 어렵습니다.

기획자는 다음 기준을 정해야 합니다.

- 최신 문서를 우선할 것인가?
- 정책 문서를 상품 설명보다 우선할 것인가?
- 담당 부서 승인 문서만 사용할 것인가?
- 충돌 시 답변하지 않고 확인 안내를 할 것인가?

정보가 없을 때의 처리

RAG 데이터에 답이 없는 질문도 들어올 수 있습니다.

이때 AI가 그럴듯하게 답하면 위험합니다.

기획자는 다음 안내 방식을 정해야 합니다.

상황	안내 방향
관련 문서 없음	확인된 자료가 없다고 안내
문서가 부족함	상담 또는 추가 확인 경로 안내
문서가 충돌함	단정하지 않고 기준 확인 필요 안내
권한이 없음	접근 가능한 범위에서만 답변

좋은 RAG는 모르는 것을 모른다고 말할 수 있어야 합니다.

RAG 데이터 설계서에 들어갈 내용

항목	작성 내용
대표 질문	사용자가 자주 물을 질문
근거 문서	질문에 답할 문서 목록
포함/제외 기준	사용할 문서와 제외할 문서 기준
Chunk 기준	문서를 나누는 단위
메타데이터	검색과 출처 표시에 필요한 정보
관리 기준	업데이트, 삭제, 충돌 처리 방식
실패 안내	답이 없을 때의 응답 원칙

이 표가 있으면 개발자와 데이터 준비 방향을 맞추기 쉽습니다.

데이터 품질 체크

RAG에 넣기 전 다음을 점검합니다.

기준	확인 질문
정확성	문서 내용이 사실과 맞는가?
최신성	오래된 정보가 섞여 있지 않은가?
완전성	대표 질문에 답할 수 있는가?
구조화	제목, 항목, 조건이 구분되어 있는가?
검색성	질문과 연결될 단위로 나뉘어 있는가?
안전성	공개하면 안 되는 정보가 제거되었는가?

데이터 품질은 RAG 답변 품질의 출발점입니다.

기획자가 마지막으로 확인할 질문

RAG 데이터 설계를 마치기 전에 다음을 점검합니다.

- 이 데이터로 사용자의 대표 질문에 답할 수 있는가?
- 답변 근거가 되는 문서가 명확한가?
- 문서 조각이 너무 크거나 작지 않은가?
- 검색에 필요한 메타데이터가 있는가?
- 최신 문서와 오래된 문서를 구분할 수 있는가?
- 사용자에게 보여주면 안 되는 정보가 제외되었는가?
- 답이 없을 때의 안내 원칙이 정해져 있는가?

오늘의 정리

RAG 데이터 설계는 AI가 참고할 지식을 준비하는 일입니다.

오늘의 핵심은 세 가지입니다.

1. 사용자 질문에서 출발해 필요한 근거 문서를 정한다
2. 문서를 답변하기 좋은 Chunk와 메타데이터로 정리한다
3. 최신성, 권한, 충돌, 실패 안내까지 운영 기준을 세운다

기획자의 역할은 문서를 많이 넣는 것이 아니라

사용자 질문에 맞는 근거가 안전하게 찾아지도록 기준을 세우는 것입니다.